Algoritmi di Ottimizzazione Combinatoria e su Rete - 2024/2025

# Testing and comparing PLI and Genetic Algorithm on a Google Hashcode problem

 $Giuseppe\ Maglione\ -\ M63001777$ 

# Introduzione del problema

#### 1.1 Descrizione

Stai organizzando un hub di Hash Code e vuoi ordinare la pizza per i partecipanti. Fortunatamente, c'è una pizzeria nelle vicinanze con una pizza davvero buona. La pizzeria offre diversi tipi di pizza e, per rendere l'ordinazione del cibo interessante, possiamo ordinare al massimo una pizza di ogni tipo. Per fortuna, ci sono molti tipi di pizza tra cui scegliere! Ogni tipo di pizza ha una dimensione specificata: la dimensione è il numero di fette di pizza che contiene. In base al numero di partecipanti, hai stimato un numero massimo di fette che desideri ordinare – per ridurre gli sprechi, l'obiettivo è ordinare quante più fette di pizza possibile, ma non più del numero massimo.

### 1.2 Input

Ogni set di dati di input è fornito in un file di testo semplice contenente esclusivamente caratteri ASCII, con righe terminate da un singolo carattere "/n" (terminazioni di riga in stile UNIX). Quando una singola riga contiene più elementi, questi sono separati da singoli spazi.

La prima linea del dataset contiene le seguenti informazioni:

- Un intero M ( $1 \le M \le 10^9$ ) il numero massimo di fette di pizza da ordinare.
- $\bullet\,$  Un intero N (1  $\leq N \leq 10^5)$  il numero di tipi di pizza diversi.

La seconda riga contiene N interi: il numero di fette per ciascun tipo di pizza, in ordine non decrescente:

• 
$$S_0 \le S_1 \le \dots \le S_{N-1} \le M$$

### 1.3 Output

L'output deve contenere due righe:

- La prima riga deve contenere un solo intero K  $(0 \le K \le N)$  il numero di pizze diverse da ordinare.
- La seconda riga deve contenere K numeri i tipi di pizza da ordinare (numerati da 0 a N-1 nello stesso ordine in cui sono forniti in input).

Il numero dotale di fette nelle pizze ordinate non deve superare il valore M.

### 1.4 Punteggio

Il punteggio viene calcolato aggiungendo 1 punto per ogni fetta presente nelle pizze ordinate. Si nota la presenza di diversi dataset che rappresentano istanze separate del problema. Il puntaggio finale sarà dato dalla somma dei punteggi per ciascun dataset individuale.

# Algoritmo Genetico

#### 2.1 Richiami teorici

L'idea alla base degli Algoritmi Genetici, come accade per molti altri algoritmi euristici, si ispira a un principio della selezione naturale: l'evoluzione genetica. Il concetto è quello di far evolvere una popolazione iniziale di soluzioni attraverso specifici meccanismi di selezione, con l'obiettivo di ottenere soluzioni via via migliori in termini di funzione obiettivo.

L'evoluzione della popolazione avviene attraverso un processo di riproduzione: due individui si combinano per generare una nuova soluzione, che eredita alcune caratteristiche dai genitori, mentre altre vengono modificate in seguito all'influenza dell'ambiente. La scelta degli individui che contribuiranno alla generazione della nuova popolazione è guidata dal principio della selezione naturale, il quale stabilisce che hanno maggiori probabilità di sopravvivere e riprodursi gli individui con una fitness più elevata, ovvero quelli con una migliore capacità di adattamento. In generale, le fasi di un algoritmo genetico sono:

- 1. Codifica: Si stabilisce il formato di ciascuna soluzione del problema, stabilendone le variabili aleatorie, la loro disposizione e i valori che queste possono assumere.
- 2. **Inizializzazione e valutazione della fitness**: Si genera un insieme di soluzioni iniziale e si valuta, per ciascuna di esse, un valore di fitness.
- 3. **Selezione**: Si selezionano, secondo specifiche strategie, le coppie di soluzioni della popolazione a cui applicare gli operatori genetici.

- 4. **Generazione**: Si applicano gli operatori genetici alle coppie di soluzioni individuate al fine di generare nuovi individui.
- 5. **Sostituzione**: Le soluzioni esistenti della popolazione vengono sostituite con quelle appena generate.

Le fasi 3,4 e 5 vengono ripetute iterativamente fino al raggiungimento di una condizione di arresto prefissata.

### 2.2 Soluzione

Nel seguito sono descritti gli approcci utilizzati per la realizzazione dell'algoritmo. Per ciascuna delle fasi analizzate è presente uno pseucodice, mentre il codice completo viene riportato nell'ultima sezione del capitolo [2.3].

#### 2.2.1 Codifica degli individui

È stata adottata una codifica degli individui, e quindi delle soluzioni, che prevede di rappresentarli tramite stringhe binarie di lunghezza fissa N (il numero di tipi di pizze disponibili). Il bit i-esimo all'interno della stringa assume valore 1 se la pizza di tipo i viene ordinata, altrimenti 0.

#### 2.2.2 Prima popolazione e Fitness

Per la generazione della prima popolazione è stato scelto di adottare una tecnica mista, che prevede l'uso di tre strategie:

- Ordinamento decrescente delle fette (greedy),
- Ordinamento crescente (greedy inverso),
- Ordinamento casuale.

Questo permette di generare uno spazio delle soluzioni iniziali quanto più vasto possibile, evitando che l'algoritmo lavori su una porzione dello spazio delle soluzioni troppo ristretta. Per ciascun individuo, le fette vengono aggiunte finché la somma parziale rimane sotto il limite M.

```
def genera_prima_popolazione
      popolazione = lista vuota
2
       for individuo da 1 a DIMENSIONE_POPOLAZIONE:
4
           strategia = random(['decrescente', 'crescente', 'casuale'])
           indici = [0, 1, 2, ..., N-1]
6
           if strategia = 'decrescente':
               ordina indici per valore decrescente delle fette (greedy)
9
           else if strategia = 'crescente':
               ordina indici per valore crescente delle fette (greedy inverso)
11
           else if strategia = 'casuale':
12
               mescola casualmente gli indici
13
14
           totale = 0
15
           bitstring = [0, 0, 0, ..., 0]
           for indice i in indici:
18
               if (totale + fette[i]) <= M:</pre>
19
                   aggiorna totale
20
                   bitstring[i] = 1
           aggiungi bitstring a popolazione
      return popolazione
25
```

La funzione di fitness valuta la qualità di una soluzione sommando i valori delle fette selezionate (quelle per cui il bit è 1). Se la somma non supera M, si restituisce il totale. In caso contrario, viene applicata una penalità lineare proporzionale all'eccesso, in modo da scoraggiare le soluzioni non valide senza escluderle completamente.

```
def calcola_fitness
       totale = 0
       for indice i in bitstring:
3
           if bitstring[i] = 1:
               aggiorna totale
5
6
       if totale <= M:</pre>
           # Soluzione ammissibile: fitness = valore totale
           fitness = totale
       else:
           # Soluzione non ammissibile: applica penalita lineare
11
           penalita = totale - M
           fitness = M - penalita
13
       return fitness
```

#### 2.2.3 Generazione

La generazione dei nuovi individui consiste nel far riprodurre una coppia di soluzioni tramite un'operazione di crossover. Il crossover avviene con due punti di taglio scelti in maniera casuale: un figlio eredita una porzione intermedia del secondo genitore, mantenendo le estremità del primo.

Questo consente un buon bilanciamento tra conservazione e innovazione genetica.

```
def crossover
      punto1 = genera un punto casuale
2
      punto2 = genera un punto casuale
3
      figlio = lista vuota
       # Segmento 1: da genitore1 (posizioni 0 fino a punto1)
6
      for indice i da 0 a punto1:
           copia genitorel[i] a figlio
8
       # Segmento 2: da genitore2 (posizioni punto1 fino a punto2)
      for indice i da punto1 a punto2:
           copia genitore2[i] a figlio
13
       # Segmento 3: da genitore1 (posizioni punto2 fino alla fine)
      for indice i da punto2 a lunghezza_bitstream:
           copia genitorel[i] a figlio
17
      return figlio
18
```

La mutazione consiste nell'invertire ciascun bit (da 0 a 1 o viceversa) con una certa probabilità, permettendo di esplorare nuove soluzioni non presenti nei genitori. Notiamo anche come tale procedura sia applicata a soltanto uno dei due figli generati. Il motivo di una tale scelta è che permette di ottenere, per ciascuna riproduzione, una soluzione più conservativa che mantiene le caratteristiche dei genitori (quella senza mutazione), e una soluzione più esplorativa che subisce dei cambiamenti nei geni (quella con mutazione).

```
def muta bitstring
      bitstring_mutato = lista vuota
3
       for bit in bitstring:
           probabilita = genera_numero_casuale(0, 1)
6
           if probabilita < TASSO_MUTAZIONE:</pre>
               # MUTAZIONE: inverte il bit
               bit_nuovo = NOT bit
9
               aggiungi bit_nuovo a bitstring_mutato
           else:
11
               # NESSUNA MUTAZIONE: mantiene il bit originale
               aggiungi bit a bitstring_mutato
13
14
       return bitstring_mutato
```

#### 2.2.4 Evoluzione e Arresto

La selezione degli individui avviene tramite torneo, in cui si scelgono casualmente k individui (di default 3) e viene selezionato quello con la fitness migliore.

```
def selezione_torneo
    partecipanti = seleziona casualmente tra la popolazione

partecipanti_valutati = lista vuota
    for ogni individuo in partecipanti:
        fitness_individuo = calcola_fitness
        aggiungi (individuo, fitness_individuo) a partecipanti_valutati

ordina partecipanti_valutati per fitness (dal migliore al peggiore)
    vincitore = primo_elemento(partecipanti_valutati)

return vincitore
```

L'evoluzione della popolazione continua per un numero massimo di generazioni o fino a quando non si raggiunge un tempo limite. L'algoritmo tiene traccia del miglior individuo visto finora, aggiornandolo se viene trovata una soluzione con fitness superiore. Data la conoscenza della soluzione ottima per ogni istanza del problema, il processo può terminare anticipatamente anche nel caso in cui questa venga trovata, ovvero quando la fitness assume valore pari a M.

#### 2.2.5 Versioni precedenti

Spiagare come è evoluta la soluzione finale.

#### 2.3 Codice

Si riporta il codice completo dell'algoritmo implementato.

```
import random
  import time
3
   # parameters
  POPULATION_SIZE = 50
  NUM_GENERATIONS = 500
  MUTATION_RATE = 0.05
  TOURNAMENT SIZE = 3
8
  TIME\_LIMIT = 60
9
  def fitness(bitstring, slices, M):
11
       total = sum(s for i, s in enumerate(slices) if bitstring[i])
       if total <= M:</pre>
13
           return total
14
15
       else:
```

```
return M - (total - M) # penalita lineare
17
   def tournament_selection(population, slices, M, k=TOURNAMENT_SIZE):
18
       selected = random.sample(population, k)
19
       selected.sort(key=lambda x: fitness(x, slices, M), reverse=True)
20
       return selected[0]
21
22
   def crossover_2point(parent1, parent2):
23
       point1, point2 = sorted(random.sample(range(len(parent1)), 2))
24
       return parent1[:point1] + parent2[point1:point2] + parent1[point2:]
25
26
   def mutate(bitstring):
28
       mutated_bitstring = []
29
       for bit in bitstring:
30
           if random.random() < MUTATION_RATE:</pre>
               mutated_bitstring.append(bit ^ 1)
                                                     # inverte il bit
32
           else:
33
               mutated bitstring.append(bit) # lascia il bit inalterato
34
       return mutated_bitstring
36
   def generate_first_population(M, N, slices):
37
       population = []
38
39
       for _ in range(POPULATION_SIZE):
40
           # scegliamo casualmente in che modo generare la prima popolazione
41
           strategy = random.choice(['desc', 'asc', 'shuffle'])
42
           indices = list(range(N))
43
44
           if strategy == 'desc':
45
                indices.sort(key=lambda i: -slices[i])
                                                              # greedy
46
           elif strategy == 'asc':
47
                indices.sort(key=lambda i: slices[i])
                                                              # greedy inverso
48
           elif strategy == 'shuffle':
49
               random.shuffle(indices)
                                                               # casuale
50
           total = 0
           bitstring = [0] * N
53
54
           for i in indices:
                if total + slices[i] <= M:</pre>
56
                    total += slices[i]
                   bitstring[i] = 1
58
           population.append(bitstring)
60
       return population
62
63
   def solve(M, N, slices):
64
       start_time = time.perf_counter()
65
       population = generate_first_population(M, N, slices)
       best_individual = max(population, key=lambda x: fitness(x, slices, M))
67
       best_score = fitness(best_individual, slices, M)
68
69
       for gen in range(NUM_GENERATIONS):
70
           elapsed = time.perf_counter() - start_time
           if elapsed >= TIME_LIMIT:
72
               print(f"\t\t[Geneneration_{gen+1}]_Early_stop,_time_limit_
73
```

```
reached ({elapsed:.2f}s)")
                break
74
            new_population = []
            while len(new_population) < POPULATION_SIZE:</pre>
78
                parent1 = tournament_selection(population, slices, M)
79
                parent2 = tournament_selection(population, slices, M)
81
                child1 = crossover_2point(parent1, parent2)
                child2 = child1[:] # copia diretta
83
84
                child1 = mutate(child1)
                                          # solo il primo figlio mutato
85
86
                new_population.append(child1)
                if len(new_population) < POPULATION_SIZE:</pre>
88
                     new_population.append(child2)
89
90
            population = new_population
91
            # salva il miglior individuo
93
            current_best = max(population, key=lambda x: fitness(x, slices, M))
94
            current_score = fitness(current_best, slices, M)
95
            if current score > best score:
96
                best_individual = current_best
                best_score = current_score
99
            if gen == 0 or (gen + 1) % 50 == 0:
100
                print(f"\t\t[Geneneration_{gen+1}]_Current_best_fitness_=_{
                   best_score | ")
            if best_score == M:
                print(f"\t\t[Geneneration..{gen+1}].Early..stop,..fitness..reached...
104
                   max_score_({M})")
                break
        elapsed_time = time.perf_counter() - start_time
       return best_score, elapsed
108
109
   11 11 11
   OLD FITNESS FUNC
111
   def fitness(bitstring, slices, M):
112
        total = sum(s for i, s in enumerate(slices) if bitstring[i])
113
        return total if total <= M else 0 # penalizza se invalido
114
   77 77 77
   11 11 11
117
   OLD REPAIR FUNC
118
   def repair (bitstring, slices, M):
119
        total = sum(s for i, s in enumerate(slices) if bitstring[i])
120
        if total <= M:
121
            return bitstring
123
124
        # rimuove pizze finche rientra in M
        indices = [i for i, bit in enumerate(bitstring) if bit == 1]
        random.shuffle(indices)
126
        for i in indices:
            bitstring[i] = 0
128
```

#### CHAPTER 2. ALGORITMO GENETICO

```
total -= slices[i]
if total <= M:
break
return bitstring
```

# Programmazione Lineare Intera

#### 3.1 Soluzione

Il problema proposto può essere facilmente modellato con le tecniche della Programmazione Lineare Intera (PLI). Come risolutore del problema è stato scelto Gurobi.

#### 3.1.1 Variabili decisionali

Sono state introdotte le variabili decisionali binarie  $x_i$ , ciascuna delle quali assume valore 1 se la pizza i viene selezionata, altrimenti 0.

```
x = model.addVars(N, vtype=GRB.BINARY, name="x")
```

#### 3.1.2 Funzione obiettivo

L'obiettivo del problema è avere a disposizione quante più fette possibili, e quindi massimizzare il numero di pizze da ordinare, senza però eccedere la quantità massima M. Poiché ad ogni pizza i viene associato un corrispondente numero di fette  $s_i$ , la funzione obiettivo può essere espressa nel seguente modo.

$$\max \sum_{i=1}^{N} s_i \cdot x_i$$

In Gurobi, l'espressione diventa.

```
model.setObjective(
    quicksum(slices[i] * x[i] for i in range(N)), GRB.MAXIMIZE
    )
```

#### 3.1.3 Vincoli

Gli unici vincoli da aggiungere riguardano il numero massimo di fette da non eccedere e l'interezza della soluzione.

$$\sum_{i=1}^{N} s_i \cdot x_i \le M$$

$$x_i \in \{0, 1\} \quad \forall i = 1, \dots, N$$

Poiché il vincolo di interezza è già stato espresso nella definizione delle variabili  $x_i$ , non resta che aggiungere a Gurobi quello sul numero di fette.

```
model.addConstr(
    quicksum(slices[i] * x[i] for i in range(N)) <= M, name="max_slices"
    )</pre>
```

#### 3.2 Codice

Si riporta il codice completo della soluzione con Gurobi.

```
from gurobipy import Model, GRB, quicksum
  import time
  import sys
  import os
  from contextlib import contextmanager
  @contextmanager
   # per evitare che gurobi scriva sul terminale
8
  def suppress_stdout():
9
      with open (os.devnull, 'w') as devnull:
10
           old_stdout = os.dup(1)
11
           os.dup2(devnull.fileno(), 1)
           try:
13
               yield
14
           finally:
               os.dup2(old_stdout, 1)
               os.close(old_stdout)
18
  def solve(M, N, slices):
19
       start_time = time.perf_counter()
20
       with suppress_stdout():
21
           model = Model("pizza")
           model.Params.OutputFlag = 0 # silenzia l'output
           # cerchiamo di rendere quanto piu confrontabile possibile la
25
              soluzione di gurobi
           model.Params.Threads = 1
26
           model.Params.MIPGap = 0.0
           model.Params.Presolve = 0
28
           model.Params.Heuristics = 0
           model.Params.TimeLimit = 60
30
```

```
31
           \# variabili binarie: x[i] = 1 se prendo la pizza i, altrimenti 0
32
           x = model.addVars(N, vtype=GRB.BINARY, name="x")
33
34
           # vincolo: somma delle fette selezionate <= M</pre>
           model.addConstr(quicksum(slices[i] * x[i] for i in range(N)) <= M,</pre>
36
              name="max_slices")
37
           # funzione obiettivo: massimizzare il numero di fette
38
           model.setObjective(quicksum(slices[i] * x[i] for i in range(N)),
              GRB.MAXIMIZE)
40
           # risoluzione
41
           model.optimize()
42
           # recupera soluzione
44
           if model.SolCount > 0:
45
               total_slices = sum(slices[i] for i in range(N) if x[i].X > 0.5)
                    # somma delle fette selezionate
               elapsed = time.perf_counter() - start_time
               return total_slices, elapsed
48
           else:
49
50
               elapsed = time.perf_counter() - start_time
               return 0, elapsed # nessuna soluzione trovata
51
```

### Confronto tra le soluzioni

Le due soluzioni proposte sono state confrontate sulle 4 istanze del problema a disposizione. La difficoltà, espressa in termini di dimensioni del dataset, aumenta al proseguire delle istanze. Ad entrambi i risolutori è stato assegnato un tempo massimo di esecuzione pari a 60 secondi e una modalità di esecuzione su singolo thread (differentemente da come lavora in genere Gurobi), in modo da ottenere dei risultati che fossero quanto più confrontabili possibile. Per ciascuna delle soluzioni riportate, viene anche mostrato il tempo che è stato richiesto per calcolarla-

#### 4.1 Risultati

I valori di output per ciascuna soluzione vengono riportati di seguito.

```
RISOLUZIONE ==
        Dataset: Datasets/small.in
3
        Max fette: 100
        Numero tipi di pizza: 10
        Lista fette per pizza: [4, 14, 15, 18, 29, 32, 36, 82, 95, 95]
         [] Risoluzione con PLI in corso...
           Risoluzione con Algoritmo Genetico in corso...
               [Geneneration 1] Current best fitness = 99
9
               [Geneneration 50] Current best fitness = 99
               [Geneneration 100] Current best fitness = 99
12
               [Geneneration 150] Current best fitness = 99
               [Geneneration 173] Early stop, fitness reached max score
                  (100)
     RISULTATI
14
        PLI -> Score: 100, Tempo: 0.0085s
15
        Genetico -> Score: 100, Tempo: 0.1321s
16
17
```

```
RISOLUZIONE ==
         Dataset: Datasets/medium.in
19
         Max fette: 4500
         Numero tipi di pizza: 50
         Lista fette per pizza: [...]
         [] Risoluzione con PLI in corso...
23
         [] Risoluzione con Algoritmo Genetico in corso...
24
               [Geneneration 1] Current best fitness = 4498
               [Geneneration 50] Current best fitness = 4499
26
               [Geneneration 100] Current best fitness = 4499
27
               [Geneneration 113] Early stop, fitness reached max score
28
                   (4500)
   == RISULTATI ==
29
         PLI -> Score: 4500, Tempo: 0.0283s
30
         Genetico -> Score: 4500, Tempo: 0.1928s
31
   == RISOLUZIONE ==
         Dataset: Datasets/big.in
34
         Max fette: 100000000
         Numero tipi di pizza: 2000
36
         Lista fette per pizza: [...]
37
         [] Risoluzione con PLI in corso...
38
         [] Risoluzione con Algoritmo Genetico in corso...
39
               [Geneneration 1] Current best fitness = 999999725
40
               [Geneneration 50] Current best fitness = 999999725
41
               [Geneneration 100] Current best fitness = 999999725
42
               [Geneneration 150] Current best fitness = 999999725
43
               [Geneneration 200] Current best fitness = 999999725
44
               [Geneneration 250] Current best fitness = 999999725
45
               [Geneneration 300] Current best fitness = 999999725
46
               [Geneneration 350] Current best fitness =
                                                           999999725
47
               [Geneneration 400] Current best fitness = 999999725
48
               [Geneneration 450] Current best fitness = 999999725
49
               [Geneneration 500] Current best fitness = 999999725
50
   == RISULTATI ==
         PLI -> Score: 1000000000, Tempo: 2.1111s
         Genetico -> Score: 999999725, Tempo: 16.0980s
53
54
   == RISOLUZIONE ==
         Dataset: Datasets/extra.in
56
         Max fette: 50500000
57
         Numero tipi di pizza: 10000
58
         Lista fette per pizza: [...]
59
         [] Risoluzione con PLI in corso...
         [] Risoluzione con Algoritmo Genetico in corso...
61
               [Geneneration 1] Current best fitness = 504999983
               [Geneneration 50] Current best fitness = 504999983
63
               [Geneneration 100] Current best fitness = 504999983
64
               [Geneneration 150] Current best fitness = 504999983
               [Geneneration 200] Current best fitness = 504999983
66
               [Geneneration 250] Current best fitness = 504999983
67
               [Geneneration 300] Current best fitness = 504999983
               [Geneneration 350] Current best fitness = 504999999
69
               [Geneneration 400] Current best fitness = 504999999
70
               [Geneneration 450] Current best fitness = 504999999
71
               [Geneneration 495] Early stop, time limit reached (60.07s)
```

#### 4.2 Conclusioni

Riportiamo in una forma più compatta i risultati precedentemente ottenuti.

Dataset	Pizze (N)	Fette (M)	Score PLI	Tempo PLI (s)	Score Genetico	Tempo Genetico (s)
small	10	100	100	0.0085	100	0.1321
medium	50	4500	4500	0.0283	4500	0.1928
big	2000	$10^{9}$	$10^{9}$	2.1111	999,999,725	16.0980
extra	10,000	505M	0	60.0578	504,999,999	60.0680

Table 4.1: Confronto tra PLI e Algoritmo Genetico su diversi dataset.

Dai test eseguiti sulle istanze di dimensioni crescenti, è possibile trarre alcune considerazioni finali sulle soluzioni con Programmazione Lineare Intera (PLI) e Algoritmo Genetico proposte.

- Per le istanze di dimensioni ridottre o medie, entrambi gli approcci trovano rapidamente la soluzione ottima.
  - Nei dataset small e medium (10–50 pizze), la PLI risolve in pochi millisecondi.
  - L'algoritmo genetico converge altrettanto bene, seppur con un tempo leggermente maggiore.
- Nel caso di istanze grandi (2000 pizze), la soluzione con PLI resta ancora efficace.
  - Trova una soluzione ottima in appena 2 secondi.
  - L'algoritmo genetico fornisce una soluzione quasi ottima (con un errore di 275 fette su un miliardo), in circa 16 secondi.
- Invece, su dataset molto grandi (10.000+ pizze), la PLI fallisce completamente.
  - Non restituisce alcuna soluzione entro il tempo limite impostato (60 secondi).
  - L'algoritmo genetico, pur richiedendo anch'esso l'intero tempo disponibile, riesce a
    costruire una soluzione altamente soddisfacente e prossima al massimo teorico (con un
    errore di 1 sola fetta su 505 milioni).

Come c'era da aspettarsi dalla teoria, i risultati ottenuti evidenziano come l'approccio genetico sia più robusto e scalabile quando si affrontano problemi su larga scala, mentre la PLI tende addirittura a non convergere entro tempi utili. L'algoritmo genetico, pur essendo più lento su istanze semplici, si dimostra quindi più stabile e adattabile quando la dimensione del problema cresce. In conclusione, in ambienti con vincoli di tempo o risorse computazionali, la metaeuristica genetica si rivela una scelta più affidabile.